

Aprendizaje Supervisado

Conceptos, Modelos, Métricas y Ajuste de Hiperparámetros

Fundamentos de Machine Learning

Pasos del Aprendizaje



1. Datos

Se recopilan datos históricos con etiquetas. El dataset se divide en conjuntos de entrenamiento (Train) y prueba (Test) para evitar el sobreajuste y evaluar de forma imparcial.



2. Entrenamiento

Se selecciona el modelo adecuado. El algoritmo analiza los datos de entrenamiento y ajusta sus parámetros internos para aprender la relación entre las características y las etiquetas.



3. Predicción

Una vez entrenado, el modelo utiliza el conjunto de prueba para predecir salidas. Estas predicciones se comparan con los valores reales para evaluar el rendimiento general.

Clasificación vs Regresión

Clasificación

El objetivo es predecir una etiqueta o categoría discreta para una nueva observación.

- **Tipos:** Binaria (dos clases), Multiclase o Multietiqueta.
- **Ejemplo:** Filtrar correos como "Spam" o "No Spam".
- **Ejemplo:** Diagnóstico de enfermedades médicas.

Regresión

El objetivo es predecir un valor numérico continuo basado en variables independientes.

- **Tipos:** Lineal simple, Múltiple, Polinómica.
- **Ejemplo:** Estimar el precio de venta de una propiedad.
- **Ejemplo:** Predecir la temperatura climática de mañana.

Métricas de Regresión



MAE

Error Absoluto Medio: Mide el promedio de los errores en valor absoluto. Es menos sensible a los valores atípicos (outliers) y nos da una idea del error general.



MSE & RMSE

Error Cuadrático Medio: Penaliza los errores grandes al elevarlos al cuadrado. Muy usado para optimización matemática.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i^2$$



R² Score

Coefficiente de Determinación: Mide la proporción de la varianza en la variable dependiente que es predecible. Un valor más cercano a 1 indica un ajuste excelente.

Métricas de Clasificación

Para evaluar la clasificación utilizamos la Matriz de Confusión y sus métricas derivadas:

- **Accuracy (Exactitud):** Cuántas veces acertó el modelo en total. Útil solo para datasets balanceados.
- **Precision:** De lo predicho como positivo, el porcentaje correcto. Evita falsos positivos.
- **Recall (Sensibilidad):** De los positivos reales, el porcentaje encontrado. Evita falsos negativos.
- **F1-Score:** Balance entre Precision y Recall. Esencial para datasets desbalanceados.

Matriz de confusión		Estimado por el modelo			
		Negativo (N)	Positivo (P)		
Real	Negativo	a: (TN)	b: (FP)		
	Positivo	c: (FN)	d: (TP)	Precisión ("precision") Porcentaje predicciones positivas correctas:	$d/(b+d)$
		Sensibilidad, exhaustividad ("Recall") Porcentaje casos positivos detectados	Especificidad ("Specificity") Porcentaje casos negativos detectados	Exactitud ("accuracy") Porcentaje de predicciones correctas (No sirve en datasets poco equilibrados)	
		$d/(d+c)$	$a/(a+b)$	$(a+d)/(a+b+c+d)$	

Modelos de Aprendizaje Supervisado



Regresión Logística

Modelo estadístico que estima la probabilidad usando una función sigmoide. Es simple, rápido de entrenar y funciona como un excelente baseline para clasificación binaria.



KNN

K-Nearest Neighbors clasifica un punto basándose en la mayoría de sus "k" vecinos más cercanos. Es intuitivo y no asume formas lineales en la distribución de los datos.



Árboles de Decisión

Estructura que divide los datos con reglas jerárquicas simples, como un diagrama de flujo. Altamente interpretable y capaz de capturar relaciones no lineales complejas.

Modelos de Aprendizaje Supervisado



Random Forest

Un ensamble (grupo) de múltiples árboles de decisión. Mejora drásticamente la precisión general y reduce el problema de sobreajuste propio de un solo árbol de decisión.



SVM

Las Máquinas de Vectores de Soporte buscan el hiperplano óptimo para separar las clases con el margen más amplio posible. Es muy robusto para datos de alta dimensión.



Naive Bayes

Basado en el teorema de Bayes, asume independencia total entre las variables. A pesar de su simplicidad, es altamente eficiente en volúmenes grandes, especialmente en texto.

Ajuste de Hiperparámetros

No basta con elegir un modelo; es crucial afinar su configuración interna (hiperparámetros) para maximizar el rendimiento y evitar el sobreajuste.

Técnicas como GridSearchCV evalúan múltiples combinaciones automáticamente. Por ejemplo, se prueba el parámetro `max_depth` en Árboles, o `n_neighbors` en KNN. Este proceso se combina con Validación Cruzada (CV) para asegurar que el modelo sea generalizable a datos nuevos y desconocidos.



Comparativa de Modelos

Modelo	Cómo Funciona	Casos de Uso Principales
Regresión Logística	Probabilidad mediante función sigmoide	Clasificación binaria (Fraude, Spam)
KNN	Busca puntos vecinos más similares	Datos pequeños, relaciones no lineales
Árboles de Decisión	Reglas jerárquicas e interpretables	Aprobación de créditos, decisiones claras
Random Forest	Combina múltiples árboles (Ensamble)	Datos complejos, segmentación de clientes
SVM	Halla el hiperplano óptimo entre clases	Clasificación de imágenes o alta dimensión

Fin de la Presentación

ARTIFICIAL
INTELLIGENCE

Gracias por tu atención.